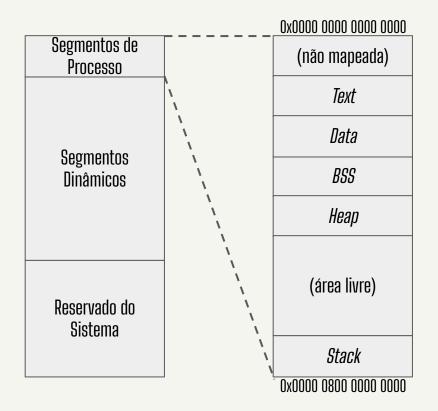
Software Básico

Aula #03 Código e Dados: Estrutura e Expressões Aritméticas

Como funciona as seções de código e dados? Como identificar programas em *assembly* (AMD64)? Como funcionam expressões aritméticas?

Ciência da Computação - BCC2 - 2023/02 Prof. Vinícius Fülber Garcia

Relembrando



Seções do segmento de processo:

- *Text*: código
- Data: dados globais inicializados
- BSS: dados não inicializados
- *Heap*: variáveis dinâmicas
- Stack: pilha de execução

Código e Dados: Escopo

0x0000 0000 0000 0000							
(não mapeada)							
Text							
Data							
BSS							
Неар							
(área livre)							
Stack							

O foco desta aula, e das próximas também, será explorar a seção de código (*text*) e dados (*data*).

- Atribuições e variáveis globais
- Expressões aritméticas
- Estruturas de repetição
- Estruturas condicionais
- Vetores

Tradução de programas em C para *assembly* (AMD64), gerando aplicações com funcionalidade equivalente.

```
int main() {
    return 0;
}
```

```
.section .text
.global _start
_start:
_movq $60, %rax
movq $0, %rdi
syscall
```

Lembram do programa mais básico possível que criamos na última aula?

Vamos voltar a ele e ver uma tradução deste (feita a mão) para código *assembly*.

Vamos analisar parte a parte!

```
int main() {
    return 0;
}
```

```
.section .text
.global _start
_start:
  movq $60, %rax
  movq $0, %rdi
  syscall
```

DEFINIÇÃO DE SEÇÃO

As seções de um programa *assembly* são definidas utilizando a diretiva ".section" seguido de ".nome" (da seção), separados por espaço.

A seção *text* é obrigatória!

```
int main(){
    return 0:
.section .text
.global start
start:
 movq $60, %rax
 movq $0, %rdi
 syscall
```

DEFINIÇÃO DE SÍMBOLOS GLOBAIS

Símbolos globais são referências em um código *assembly* e são definidos pela diretiva ".global". Tais símbolos são reconhecidos em diferentes partes do programa *assembly*.

O símbolo _*start* é obrigatoriamente global!

```
int main(){
    return 0:
.section .text
.global start
 start:
 movq $60, %rax
 movq $0, %rdi
  syscall
```

DEFINIÇÃO DE REFERÊNCIA INICIAL

O símbolo _start define o ponto de início de execução do programa. Ou seja, é um símbolo único e necessário para a execução de um programa escrito em assembly.

O símbolo _*start* é obrigatório!

```
int main(){
    return 0;
.section .text
.global start
start:
 movq $60, %rax
 movq $0, %rdi
  syscall
```

A INSTRUÇÃO *mov*

A instrução *mov* serve para mover um valor (primeiro argumento) para um local (segundo argumento).

- movq: valor com 64 bits
- movl: valor com 32 bits
- movw: valor com 16 bits
- movb: valor com 8 bits

```
int main(){
    return 0:
.section .text
.global start
start:
 movq $0, %rdi
  syscall
```

O PRIMEIRO ARGUMENTO DO mov

O primeiro argumento indica o valor o qual deve ser copiado. Este pode ser uma constante (imediato - \$), estar contido em um registrador (reg. - %) ou estar contido em uma posição de memória (direto - OxO... ou rótulo de variável).

```
int main(){
   return 0:
.section .text
.global start
start:
 movq $60, %rax
 movq $0, %rdi
  syscall
```

O SEGUNDO ARGUMENTO DO *mov*

O segundo argumento define o destino para onde o valor (primeiro argumento) deve ser copiado. Este pode ser um registrador (reg. - %) ou posição de memória (direto - OxO... ou rótulo de variável).

IMPORTANTE!!

Uma instrução não pode realizar dois acessos à memória! Apenas um acesso pode ser previsto por instrução.

movq 0x00.. 0x01.. (não pode!)

Nesse caso, você pode, por exemplo, utilizar um registrador com sentinela do valor, executando duas operações de movimentação.

INTERESSANTE!!

A maioria das operações *assembly* do AMD64 tem dois operandos.

O primeiro operando é tipicamente uma fonte de dados e o segundo o destino do resultado da operação (podendo ou não ser uma fonte de dados também).

NECESSÁRIO!!

Dentro da nossa arquitetura, temos disponíveis dezesseis (16) registradores de propósito geral.

Reg.	%r0	%r1	%r2	%r3	%r4	%r5	%r6	%r7	%r8	%r9	%r10	%r11	%r12	%r13	%r14	%r15
Nome	%rax	%rcx	%rdx	%rbx	%rsp	%rbp	%rsi	%rdi	%r8	%r9	%r10	%r11	%r12	%r13	%r14	%r15

CURIOSO!!

Existe uma progressão histórica na disponibilidade e tamanho dos registradores.

ANO	MODELO	REGISTRADORES	TAMANHO	QUANTIDADE
1978	8086	AX, BX,, IP	16 bits	4-16 (8-8)
1982	80186	AX, BX,, IP	16 bits	4-16 (8-8)
1982	80286	AX, BX,, IP	16 bits	4-16 (8-8)
1985	80386	EAX, EBX,, EIP	32 bits	8-32
1989	80486	EAX, EBX,, EIP	32 bits	8-32
1993	Pentium	EAX, EBX,, EIP	32 bits	8-32
2004	Pentium	RAX, RBX,, RIP	64 bits	8-64
2008	13, i5, i7	RAX, RBX,, RIP	64 bits	16-64

```
int main(){
    return 0:
.section .text
.global start
start:
 movq $60, %rax
 movq $0, %rdi
  syscall
```

A PRIMEIRA OPERAÇÃO

Conforme o que já estudamos, podemos interpretar sintaticamente a primeira operação do nosso programa.

O que ela faz?

```
int main(){
    return 0:
.section .text
.global start
start:
 movq $60, %rax
 movq $0, %rdi
  syscall
```

A PRIMEIRA OPERAÇÃO

Mas a grande questão é: o que a operação significa?

Quando o sistema lê o valor sessenta (60 - dec.) em %rax, o mesmo finaliza o processo.

```
int main(){
    return 0:
.section .text
.global start
start:
 movq $60, %rax
 movq $0, %rdi
  syscall
```

A SEGUNDA OPERAÇÃO

A segunda operação também se dá pela instrução *mov*.

Quando finalizado o processo, o registrador %rdi armazena o valor de retorno do mesmo.

```
int main(){
    return 0:
.section .text
.global start
start:
 movq $60, %rax
 movq $0, %rdi
  syscall
```

A TERCEIRA OPERAÇÃO

A terceira operação consiste em uma nova instrução: *syscall*

Em suma, essa instrução chama o sistema, que lê e aplica a operação que informamos em %rax.

Um Resumo: Syscall

Mas vamos entender um pouco melhor...

Como vimos anteriormente, um processo recebe um espaço de memória, com endereços virtuais, para trabalhar.

O processo não pode, de maneira alguma, acessar recursos fora do seu espaço particular.

Para utilizar tais recursos, o processo usa um intermediário: o SO!

Um Resumo: Syscall

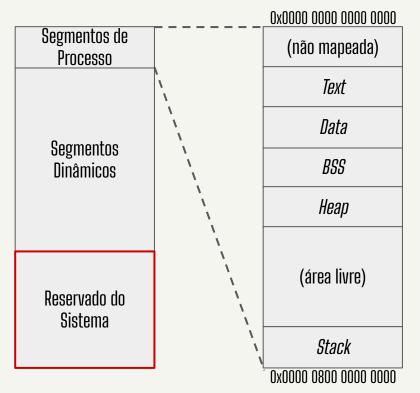
Exemplos de recursos externos:

- Finalização do processo
- Dados da memória secundária
- Operações em dispositivos externos

Existem protocolos específicos para cada tipo de operação de sistema: vamos analisar eles nas aulas futuras.

Por enquanto: a *syscall* serve para chamar o sistema!

Um Resumo: Syscall



Mas o que "chamar o sistema" significa na prática?

Todo o processo tem uma "janela" para o sistema operacional.

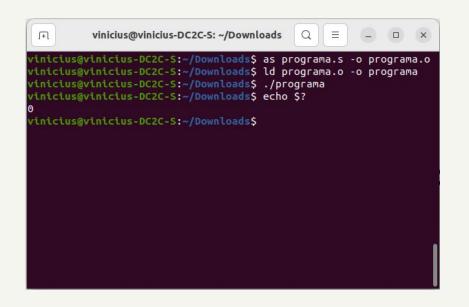
Desvio de fluxo de execução e, se precisar, retorno.

Legal! Já compreendemos o nosso programa escrito em *assembly*.

Mas como transformar ele em um executável?

Precisaremos utilizar um montador para gerar códigos-objeto e, em seguida, executar um ligador sobre os objetos para criarmos um executável.

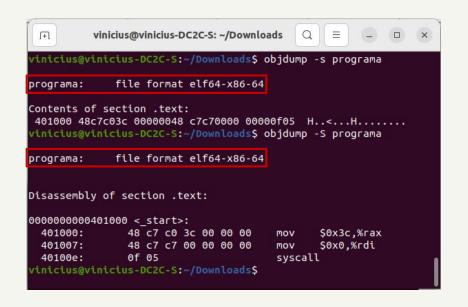
No contexto do gcc, nosso montador se chama "as" e nosso ligador se chamada "ld".



Vamos considerar que salvamos o nosso programa escrito em assembly como "programa.s".

Primeiro, geramos o arquivo de código-objeto "programa.o" usando o "as".

Então, geramos o executável "programa" com o "ld".



E no arquivo executável, como essas operações se comportam em binário?

Analisando com *objdump* vamos primeiros observar que de fato temos um **ELF para arquitetura AMD64**.

```
vinicius@vinicius-DC2C-S: ~/Downloads
 rinicius@vinicius-DC2C-S:~/Downloads$ objdump -s programa
programa:
              file format elf64-x86-64
Contents of section .text:
 401000 48c7c03c 00000048 c7c70000 00000f05 H..<...H......
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -S programa
programa:
              file format elf64-x86-64
Disassembly of section .text:
0000000000401000 < start>:
                48 c7 c0 3c 00 00 00
                                                $0x3c,%rax
  401000:
                                         MOV
                48 c7 c7 00 00 00 00
                                                S0x0.%rdi
  401007:
                                         MOV
                0f 05
                                         syscall
  40100e:
vinicius@vinicius-DC2C-S:~/Downloads$
```

Em seguida, podemos observar a **seção** *text* no arquivo.

Na primeira visualização (-s), temos apenas os bytes em hexadecimal; na segunda (-S), temos as operações em *assembly*.

```
vinicius@vinicius-DC2C-S: ~/Downloads
 rinicius@vinicius-DC2C-S:~/Downloads$ objdump -s programa
programa:
              file format elf64-x86-64
Contents of section .text:
 401000 48c7c03c 00000048 c7c70000 00000f05 H..<...H......
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -S programa
              file format elf64-x86-64
programa:
Disassembly of section .text:
0000000000401000 < start>:
                48 c7 c0 3c 00 00 00
                                                $0x3c,%rax
  401000:
                                         MOV
  401007:
                48 c7 c7 00 00 00 00
                                                S0x0.%rdi
                                        MOV
                0f 05
  40100e:
                                        svscall
vinicius@vinicius-DC2C-S:~/Downloads$
```

Então, encontramos a posição de memória inicial da seção: 401000

Note a diferença, em termos da exibição das posições de memória, entre as duas visualizações.

```
1
           vinicius@vinicius-DC2C-S: ~/Downloads
 rinicius@vinicius-DC2C-S:~/Downloads$ objdump -s programa
programa:
              file format elf64-x86-64
Contents of section .text:
 401000 48c7c03c 00000048 c7c70000 00000f05 H..<...H......
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -S programa
              file format elf64-x86-64
programa:
Disassembly of section .text:
00000000000401000 < start>:
                48 c7 c0 3c 00 00 00
                                                $0x3c,%rax
  401000:
                                         MOV
                48 c7 c7 00 00 00 00
                                                $0x0,%rdi
  401007:
                                         MOV
                0f 05
                                         syscall
  40100e:
vinicius@vinicius-DC2C-S:~/Downloads$
```

E então podemos identificar a primeira instrução:

- 48: código para reg. 64
- C7 CO: move to %rax
- 3c 00 00 00: constante 60

Lembre-se, a arquitetura AMD64 é *little endian*!

```
(+)
           vinicius@vinicius-DC2C-S: ~/Downloads
 rinicius@vinicius-DC2C-S:~/Downloads$ objdump -s programa
programa:
              file format elf64-x86-64
Contents of section .text:
 401000 48c7c03c 00000048 c7c70000 00000f05 H..<...H......
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -S programa
              file format elf64-x86-64
programa:
Disassembly of section .text:
0000000000401000 < start>:
                48 c7 c0 3c 00 00 00
                                                $0x3c,%rax
  401000:
                                         MOV
                48 c7 c7 00 00 00 00
                                                S0x0.%rdi
  401007:
                                         MOV
                0f 05
  40100e:
                                         svscall
vinicius@vinicius-DC2C-S:~/Downloads$
```

Em seguida, a segunda instrução:

- 48: código para reg. 64
- C7 C7: move to %rdi
- 00 00 00 00: constante 0

```
1
           vinicius@vinicius-DC2C-S: ~/Downloads
 rinicius@vinicius-DC2C-S:~/Downloads$ objdump -s programa
programa:
              file format elf64-x86-64
Contents of section .text:
 401000 48c7c03c 00000048 c7c70000 00000f05 H..<...H......
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -S programa
              file format elf64-x86-64
programa:
Disassembly of section .text:
0000000000401000 < start>:
                48 c7 c0 3c 00 00 00
                                                $0x3c,%rax
  401000:
                                         MOV
                48 c7 c7 00 00 00 00
                                                S0x0.%rdi
  401007:
                                         MOV
  40100e:
                0f 05
                                         svscall
vinicius@vinicius-DC2C-S:~/Downloads$
```

Por fim, a terceira instrução:

• Of 05: código para *syscall*

Opa, apenas dois bytes nesta instrução?

Sim, estamos lidando com uma arquitetura CISC!

```
1
           vinicius@vinicius-DC2C-S: ~/Downloads
 vinicius@vinicius-DC2C-S:~/Downloads$ objdump -s programa
programa:
              file format elf64-x86-64
Contents of section .text:
 401000 48c7c03c 00000048 c7c70000 00000f05 H..<...H......
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -S programa
              file format elf64-x86-64
programa:
Disassembly of section .text:
0000000000401000 < start>:
                48 c7 c0 3c 00 00 00
                                                $0x3c,%rax
  401000:
                                         MOV
  401007:
                48 c7 c7 00 00 00 00
                                                $0x0,%rdi
                                         MOV
  40100e:
                0f 05
                                         syscall
 vinicius@vinicius-DC2C-S:~/Downloads$
```

Um ponto interessante é: os endereços já estão preparados para a região de memória do segmento do processo quando em execução!

```
0x000 0040 0000 = 0x000 0040 1000 = 0x800 0000 0000 

É valido!
```

Mas quem define esses endereços? O ligador (ld)!

```
vinicius@vinicius-DC2C-S: ~/Downloads
 rinicius@vinicius-DC2C-S:~/Downloads$ objdump -s programa
programa:
              file format elf64-x86-64
Contents of section .text:
 401000 48c7c03c 00000048 c7c70000 00000f05 H..<...H......
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -S programa
              file format elf64-x86-64
programa:
Disassembly of section .text:
0000000000401000 < start>:
                48 c7 c0 3c 00 00 00
                                                $0x3c,%rax
  401000:
                                         MOV
  401007:
                48 c7 c7 00 00 00 00
                                                S0x0.%rdi
                                         MOV
  40100e:
                0f 05
                                         svscall
 vinicius@vinicius-DC2C-S:~/Downloads$
```

Quando nós executamos o programa, o carregador coloca as seções em memória (nem todas).

A CPU busca a primeira instrução (demarcada por _*start*), decodifica e executa a mesma

--

```
int main() {
  int a = 5, b = 10;
  return (a + b);
}
```

```
.section .data
A: .quad 5
B: .quad 10
.section .text
.globl _start
_start:
  movq A, %rdi
  addq B, %rdi
  movq $60, %rax
  syscall
```

Considerando a versão do programa ao lado, vamos analisar a sua transcrição para *assembly*.

Agora as coisas já estão começando a ficar um pouco mais complexas!

```
int main() {
  int a = 5, b = 10;
  return (a + b);
}
```

```
.section .data
A: .quad 5
B: .quad 10
.section .text
.globl _start
_start:
  movq A, %rdi
  addq B, %rdi
  movq $60, %rax
  syscall
```

DEFINIÇÃO DA SEÇÃO *DATA*

Além da seção *text*, onde as instruções são alocadas, agora também contamos com a seção *data*, para as nossas variáveis inicializadas!

```
int main() {
   int a = 5, b = 10;
   return (a + b);
}
```

```
.section .data
A: .quad 5
B: .quad 10
.section .text
.globl _start
_start:
  movq A, %rdi
  addq B, %rdi
  movq $60, %rax
  syscall
```

DECLARAÇÃO E INICIALIZAÇÃO DE VARIÁVEIS

A declaração de variáveis começa pela definição de um rótulo para a mesma, este seguido por ":".

Então define-se a quantidade de bits para a variável e o seu valor inicial.

```
int main() {
  int a = 5, b = 10;
  return (a + b);
}
```

```
.section .data
A: .quad 5
B: .quad 10
.section .text
.globl _start
_start:
  movq A, %rdi
  addq B, %rdi
  movq $60, %rax
  syscall
```

DECLARAÇÃO E INICIALIZAÇÃO DE VARIÁVEIS

Os principais tamanhos de variáveis disponíveis são:

- .byte: 8 bits
- .word: 16 bits
- .long: 32 bits
- .quad: 64 bits

```
int main(){
   int a = 5, b = 10;
   return (a + b);
.section .data
 A: .quad 5
 B: .quad 10
.section .text
.globl start
 start:
 movq A, %rdi
 addq B, %rdi
 movq $60, %rax
  syscall
```

DEFINIÇÃO DA SEÇÃO *TEXT*

Neste ponto, não há nada novo. Definimos a seção *text* normalmente e definimos o seu ponto inicial para a execução.

```
int main(){
  int a = 5, b = 10;
  return (a + b);
.section .data
A: .quad 5
 B: .quad 10
.section .text
.globl start
start:
 movq A, %rdi
 addq B, %rdi
 movq $60, %rax
  syscall
```

A PRIMEIRA INSTRUÇÃO

A primeira instrução também não nos traz nada novo, consiste da operação *mov*.

A principal novidade é a utilização de endereçamento direto no primeiro argumento.

```
int main() {
  int a = 5, b = 10;
  return (a + b);
}
```

```
.section .data
A: .quad 5
B: .quad 10
.section .text
.globl _start
_start:
  movq A, %rdi
  addq B, %rdi
  movq $60, %rax
  syscall
```

A SEGUNDA INSTRUÇÃO

A segunda instrução é nova! Ela consiste na operação *add*.

A operação *add* recebe dois parâmetros tal qual a operação *mov* (mesmas possibilidades e restrições).

```
int main() {
  int a = 5, b = 10;
  return (a + b);
}
```

```
.section .data
A: .quad 5
B: .quad 10
.section .text
.globl _start
_start:
_movq A, %rdi
addq B, %rdi
movq $60, %rax
syscall
```

A SEGUNDA INSTRUÇÃO

A segunda instrução é nova! Ela consiste na operação *add* (operação de soma).

A operação *add* recebe dois parâmetros tal qual a operação *mov* (mesmas possibilidades, restrições e resultados).

```
int main() {
  int a = 5, b = 10;
  return (a + b);
}
```

```
.section .data
A: .quad 5
B: .quad 10
.section .text
.globl _start
_start:
  movq A, %rdi
  addq B, %rdi
  movq $60, %rax
  syscall
```

A TERCEIRA INSTRUÇÃO E A QUARTA INSTRUÇÃO

Bloco que ajusta a requisição e realiza a *syscall* para o encerramento do processo.

```
vinicius@vinicius-DC2C-S: ~/Downloads
 [+]
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -s programa
             file format elf64-x86-64
programa:
Contents of section .text:
401000 488b3c25 00204000 48033c25 08204000 H.<%. @.H.<%. @.
401010 48c7c03c 0000000f 05
                                             H..<....
Contents of section .data:
402000 05000000 00000000 0a000000 00000000 ......
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -S programa
             file format elf64-x86-64
programa:
Disassembly of section .text:
0000000000401000 < start>:
                48 8b 3c 25 00 20 40
  401000:
                                               0x402000, %rdi
 401007:
               48 03 3c 25 08 20 40
                                               0x402008,%rdi
  401008:
                                        add
  40100f:
 401010:
               48 c7 c0 3c 00 00 00
                                               $0x3c,%rax
                                        mov
               0f 05
 401017:
                                        syscall
 inicius@vinicius-DC2C-S:~/Downloads$
```

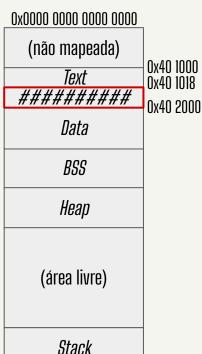
Analisando o executável gerado após a montagem (as) e ligação (ld) do nosso programa podemos notar a presença de uma nova seção: data.

Está seção define o **espaço de memória e os valores iniciais** das nossas variáveis.

```
vinicius@vinicius-DC2C-S: ~/Downloads
                                                 \equiv
 [+]
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -s programa
              file format elf64-x86-64
programa:
Contents of section .text:
401000 488b3c25 00204000 48033c25 08204000 H.<%. @.H.<%. @.
401010 48c7c03c 0000000f 05
                                             H..<....
Contents of section .data:
402000 05000000 00000000 0a000000 00000000 .....
vinicius@vinicius-DC2C-S:~/Downloads$ objdump -S programa
              file format elf64-x86-64
programa:
Disassembly of section .text:
0000000000401000 < start>:
                                               0x402000,%rdi
 401000:
                48 8b 3c 25 00 20 40
 401007:
                                               0x402008,%rdi
               48 03 3c 25 08 20 40
                                        add
  401008:
 40100f:
 401010:
               48 c7 c0 3c 00 00 00
                                               $0x3c,%rax
                                        mov
               0f 05
 401017:
                                        syscall
 inicius@vinicius-DC2C-S:~/Downloads$
```

Verificando os endereços de memória disponíveis podemos deduzir algumas coisas:

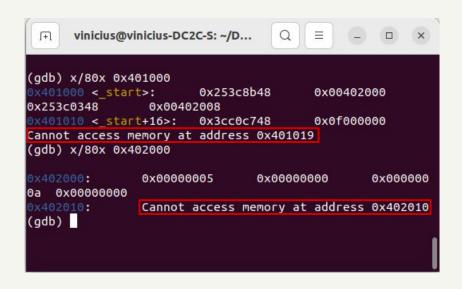
- A seção data inicia no endereço 0x402000
- A seção data ocorre depois da seção text
 - 4096 bytes a frente



0x0000 0800 0000 0000

Ok! Mas se a seção *text* começa em 0x401000 e contém apenas 24 bytes, e a seção *data* começa apenas em 0x402000, <mark>o que tem no espaço vago?</mark>

A resposta é: **nada!** Essa parte da memória tem seu acesso bloqueado para impedir injeções de código.



Notem o exame do binário com o gdb:

- Na seção text, o exame dos dados é suspenso no endereço 0x401019
- Na seção data, o exame dos dados é suspenso no endereço 0x402010

Outras Operações Aritméticas

Naturalmente, o assembly x86_64 fornece outras operações aritméticas além da adição (add) vista anteriormente. Entre as operações disponíveis, destacam-se:

- add argl arg2
- sub argl arg2
- mul arg1
- div arg1

Exercício #02

```
.section .data
A: .quad 5
B: .quad 10
.section .text
.globl _start
_start:
  movq A, %rdi
  addq B, %rdi
  movq $60, %rax
  syscall
```

Utilize o último programa estudado na aula de hoje (ao lado) e faça a sua montagem (*as*, criando um arquivo de código-objeto) e ligação (*ld*, criando um arquivo executável) e responda:

 Qual é a diferença nos endereços de memória indicados nos arquivos? Na sua opinião, qual é o motivo dessa diferença? (Dica: verifique através da aplicação objdump)

Obrigado!

Vinícius Fülber Garcia inf_ufpr_br/vinicius/viniciusfulber@ufpr_br